CẨM NANG ĐỒ ÁN NHẬP MÔN HỌC MÁY • CHỦ ĐỀ NEVER-ENDING LEARNING

TỔNG QUAN BÀI BÁO STUDD

Phát hiện Concept Drift không giám sát bằng mô hình Học trò – Thầy giáo (Cerqueira et al., Machine Learning 2023)

1. Phân tích Yêu cầu Chọn Đề tài & Lý do Chọn Bài báo STUDD

Stage 1: Selection

Theo đề cương đồ án môn học, mỗi nhóm nhận một bài báo khoa học thuộc chủ đề **Never-Ending Learning** công bố trong vòng 5 năm (60 tháng) và trải qua 5 giai đoạn: *Chọn bài (Selection)* → *Đọc hiểu (Reading)* → *Tái hiện thực nghiệm (Reproduction)* → *Phản biện lý thuyết (Theory Critique)* → *Kiểm thử chịu tải & Báo cáo (Empirical Stress Testing & Poster)*. Giảng viên đặc biệt khuyến nghị chọn bài báo sử dụng **các mô hình học máy cổ điển đã học trên lớp lý thuyết** thay vì mạng học sâu phức tạp.

- **Đúng nhánh nghiên cứu mục tiêu:** Trong 3 hướng chính (*Continual learning, Online learning, Lifelong learning*), bài báo **STUDD** thuộc chính xác nhánh **Online learning** (từ khóa: *learning on data streams, concept drift*).
- **Mô hình 100% sát chương trình học:** STUDD sử dụng trực tiếp các bộ phân loại nền tảng của `scikit-learn` (Random Forest, Decision Tree, Logistic Regression, SVM, Naive Bayes, Ridge, XGBoost) kết hợp kiểm định thống kê tuần tự Page–Hinkley.
- **Giải đáp thắc mắc về năm xuất bản & đường dẫn:** Bài báo được đăng trực tuyến sớm (*Published online*) ngày 21/06/2022 và xếp vào Số tạp chí chính thức (*Volume 112, Issue 11*) năm **2023**. Tính đến tháng 10/2026 (43–52 tháng), bài báo hoàn toàn hợp lệ quy định dưới 60 tháng. Bản trên *Springer* là bản xuất bản chính thức cuối cùng, còn bản *arXiv (2103.00903)* là bản thảo mở miễn phí có nội dung tương đương.

Trường thông tin Form	Nội dung điền chính xác (Đối chiếu từ PDF gốc của Springer)
Publication title	STUDD: a student–teacher method for unsupervised concept drift detection
Authors	Vitor Cerqueira, Heitor Murilo Gomes, Albert Bifet, Luis Torgo
Publication year / month	Năm: **2023** (Volume 112, pp. 4351–4378) • Online First: Tháng 6/2022
Publication venue	Machine Learning (Springer, ISSN: 0885-6125)
Official link (DOI)	https://doi.org/10.1007/s10994-022-06188-7 (Trang chủ bài báo trên Springer)
Open-access PDF link	https://arxiv.org/pdf/2103.00903.pdf (hoặc tải trực tiếp PDF từ trang Springer)
Quality & Proof	**Q1** (SCIE / Scopus) • Minh chứng: https://wos-journal.info/journalid/11751

Ý nghĩa tên gọi viết tắt STUDD

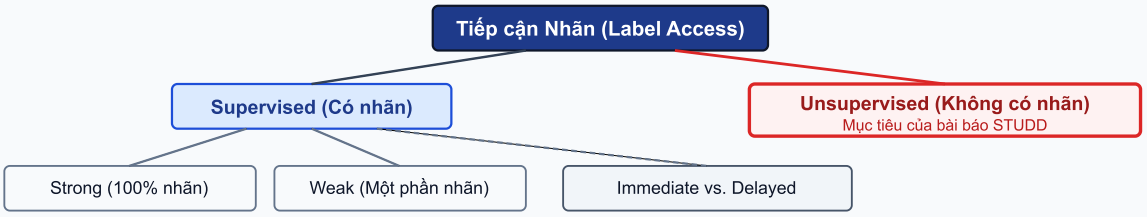
STUDD được ghép từ tên phương pháp trong tiêu đề: **STU**dent–teacher method for unsupervised concept **D**rift **D**etection (*Phương pháp Học trò – Thầy giáo để phát hiện trôi dạt khái niệm không giám sát*).

2. Giải thích Dễ hiểu Bài toán: Concept Drift & Nỗi đau Thiếu Nhãn

Stage 2: Reading (Phần 1)

Trong học máy truyền thống, ta giả định dữ liệu lúc huấn luyện và lúc chạy thực tế tuân theo cùng một quy luật tĩnh. Tuy nhiên, trên luồng dữ liệu liên tục theo thời gian ($D(X, y) = \{(X_1, y_1), ..., (X_t, y_t)\}$, gọi là **Data Stream**), phân phối xác suất đồng thời $p(X, y)$ thường xuyên biến đổi. Hiện tượng quy luật dữ liệu thay đổi theo thời gian làm mô hình dự đoán sai lệch gọi là **Concept Drift (Sự trôi dạt khái niệm)**.

- **Virtual Concept Drift (Trôi dạt ảo — thay đổi $p(X)$):** Phân phối đặc trưng đầu vào $p(X)$ thay đổi nhưng quy luật gán nhãn $p(y \mid X)$ giữ nguyên (ví dụ: độ tuổi và thu nhập trung bình của người nộp hồ sơ vay vốn dịch chuyển sang vùng mới).
- **Real Concept Drift (Trôi dạt thật — thay đổi $p(y \mid X)$):** Quy luật hậu nghiệm giữa đầu vào và nhãn mục tiêu $p(y \mid X)$ thay đổi trực tiếp, dù phân phối đầu vào $p(X)$ có thể đứng yên (ví dụ: cùng mức thu nhập như năm ngoái nhưng do suy thoái kinh tế nên khách hàng chuyển từ trả nợ tốt sang vỡ nợ).



Hình 1 (Trang 4354 bài báo): Các kịch bản tiếp cận nhãn sau khi triển khai mô hình ra thực tế.

Tại sao các thuật toán phát hiện Drift truyền thống thất bại?

Mục 2.2 & 3.1

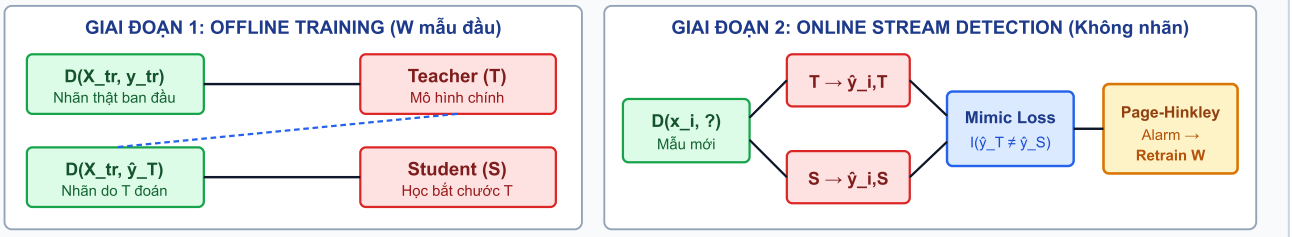
Đa số các thuật toán kinh điển như **DDM** (Gama et al., 2004), **EDDM** (Baena-Garcia et al., 2006) hay **ADWIN** (Bifet & Gavalda, 2007) đều thuộc nhóm **Supervised**: ngay sau khi mô hình dự đoán mẫu X_t, hệ thống đòi hỏi phải có ngay nhãn thật y_t để tính lỗi $L(y_t, \hat{y}_t)$. Nếu lỗi tăng vọt thì phát báo động.

> **Thực tế phũ phàng trong công nghiệp &Cách tiếp cận trước khi có STUDD**
>
> Ngoài đời thực, nhãn thật y_t thường đến rất trễ (*Delayed Feedback* — ví dụ 1 năm sau mới biết khách vay có vỡ nợ hay không) hoặc quá đắt đỏ để gán nhãn toàn bộ. Trước STUDD, các phương pháp không giám sát (*Unsupervised*) thường dùng **kiểm định thống kê Kolmogorov–Smirnov (KS-test)** trên cửa sổ trượt (**OS**), cửa sổ cố định của xác suất đầu ra (**OF** — Žliobaitė, 2010), hoặc kiểm định KS trên từng đặc trưng đầu vào (**FF** — dos Reis et al., 2016). Tuy nhiên, việc kiểm định từng đặc trưng riêng lẻ khiến **FF** báo động giả quá nhiều khi dữ liệu có số chiều lớn.

3. Kiến trúc STUDD: Mẹo "Thầy – Trò" & Kiểm định Page–Hinkley

Stage 2: Reading (Phần 2)

Lấy cảm hứng từ *Model Compression* (Buciluǎ et al., 2006) và *Knowledge Distillation* (Hinton et al., 2015), STUDD xây dựng cặp mô hình **Thầy (Teacher T)** và **Trò (Student S)**. Điểm khác biệt cốt lõi ở Mục 4.1 là: trong nén mô hình, người ta vứt bỏ Thầy và chỉ dùng Trò cho nhẹ; còn trong STUDD, **cả Thầy T và Trò S đều chạy song song ở pha Online** để lấy độ lệch giữa Trò và Thầy làm tín hiệu phát hiện Drift mà không cần nhãn thật y_t.



Hình 2: Sơ đồ tổng hợp Giai đoạn 1 (Hình 4 trang 4358) và Giai đoạn 2 (Hình 5 trang 4359) của thuật toán STUDD.

Công thức Kiểm định Tuần tự Page–Hinkley (Page, 1954)

Mục 4.2 & 5.7

Tại mỗi thời điểm t trên luồng trực tuyến, hệ thống tính sai số bắt chước nhị phân $L_t = I(\hat{y}_{t,T} \neq \hat{y}_{t,S}) \in \{0, 1\}$ (bằng 0 nếu Thầy và Trò đoán giống nhau, bằng 1 nếu cãi nhau). Bộ kiểm định **Page–Hinkley (PHT)** theo dõi xem tỷ lệ cãi nhau có tăng đột biến so với mức trung bình lịch sử $\bar{L}_t$ hay không thông qua biến tích lũy m_t:

- **Cập nhật trung bình cộng dồn:** $\bar{L}_t = \bar{L}_{t-1} + (L_t - \bar{L}_{t-1}) / t$ (với $\bar{L}_0 = 0$).
- **Cập nhật tổng độ lệch tích lũy:** $m_t = m_{t-1} + (L_t - \bar{L}_t - \delta)$, trong đó $\delta = 0.001$ (tham số độ lớn thay đổi được bài báo thiết lập ở Mục 5.7 trang 4365) và lưu giá trị nhỏ nhất $M_t = min(M_{t-1}, m_t)$.
- **Điều kiện hú còi báo động (Drift Alarm):** Khi hiệu số $PH_t = m_t - M_t > \lambda$ (ngưỡng báo động mặc định $\lambda = 50$ trong `scikit-multiflow`), hệ thống kết luận có Concept Drift!

> **Cơ chế Thích nghi (Adaptation — Mục 4.3 & Hình 6 trang 4362)**
>
> Mỗi khi PHT phát báo động tại thời điểm t, hệ thống yêu cầu con người gán nhãn thật cho W **mẫu dữ liệu gần nhất** để huấn luyện lại từ đầu (*Retrain from scratch*) cả mô hình Thầy T lẫn mô hình Trò S, đồng thời reset bộ đếm PHT.

4. Thiết lập Thực nghiệm Bài báo Gốc & Hướng dẫn Re-code Stage 3: Reproduction

Ở Mục 5 (trang 4359–4374), nhóm tác giả kiểm chứng STUDD trên **19 bộ dữ liệu luồng (Data Streams)** (giới hạn tối đa 150.000 mẫu/bộ; cửa sổ $W = 2000$ cho bộ lớn và $W = 500$ cho 6 bộ nhỏ như *Insects, AbruptInsects, Keystroke, Ozone, Outdoor, Luxembourg*). Trước khi chạy Online, bài báo dùng thủ tục **Algorithm Selection (Mục 5.6.2)**: chia W mẫu đầu thành 70% train / 30% validation để chọn tự động mô hình tốt nhất theo chỉ số **Cohen's Kappa (κ)** từ 7 thuật toán của `scikit-learn` (RF, XGB, DT, LR, SVC, RC, NB).

- **9 phương pháp đối chứng:** 2 Baselines (`BL-st` tĩnh không bao giờ cập nhật; `BL-ret` cập nhật định kỳ mỗi W mẫu), 3 phương pháp Unsupervised dùng KS-test (OS, OF, FF với $\alpha = 0.001$), và 4 biến thể Supervised (SS 100% nhãn tức thì; WS 50% nhãn; DSS trễ $W/2$ mẫu; DWS 50% nhãn + trễ $W/2$).
- **Thước đo đánh giá:** *Predictive Performance* (Cohen's Kappa κ), *Annotation Cost* (Tỷ lệ nhãn tiêu tốn so với chiều dài luồng), *Labeling Efficiency* (Tỷ số κ chuẩn hóa chia cho Cost chuẩn hóa theo `BL-st` — Công thức 1–3 trang 4372), cùng 4 chỉ số báo động ở Bảng 5: **MDR** (Tỷ lệ bỏ sót), **FAR** (Báo động giả), **MTD** (Thời gian phát hiện) và **MTFA**.

Phương pháp / Bộ dữ liệu	Cặp (T, S)	STUDD	BL-st	SS (Chuẩn)	OS (KS)	FF (KS)	Nhận xét cốt lõi từ bài báo
AbruptInsects (Kappa / Cost)	RF – RF	**0.73** / 0.28	0.59 / 0.09	0.78 / 0.19	0.79 / 0.19	0.77 / 0.66	Hình 7: Bắt kịp 2 điểm drift sát nút SS
Posture (Kappa / Cost)	XGB – RF	**0.50** / 0.02	0.34 / 0.01	0.40 / 0.08	0.49 / 0.02	0.49 / 0.74	Hình 8: Kappa vượt SS chỉ với 2% nhãn
Poker (Kappa / Cost)	DT – DT	**0.48** / 0.01	0.28 / 0.01	0.65 / 2.69	0.20 / 0.43	0.45 / 0.97	Tiết kiệm nhãn gấp 40–90 lần OS/FF
Rialto (Kappa / Cost)	XGB – XGB	**0.38** / 0.21	0.30 / 0.01	0.47 / 1.23	0.40 / 0.50	0.34 / 1.00	Chi phí nhãn bằng 1/5 so với FF và SS
Bike (Ca thất bại — Hình 9)	XGB – RF	**0.32** / 0.06	0.31 / 0.06	0.30 / 0.46	0.23 / 0.06	0.31 / 0.98	Tại t=5000: T đoán sai (κ=0), S copy 100%
MDR (Bỏ sót Drift — Bảng 5)	16 bộ	**0.19** (3/16)	NA	Benchmark	0.06	0.00	STUDD bảo thủ, bỏ sót ở 3/16 bộ
FAR / MTD (Bảng 5 trang 4371)	16 bộ	**0.00** / 0.09	NA	Benchmark	0.12 / 0.12	0.25 / 0.07	Không báo động giả (FAR=0), MTD=0.09

Hướng dẫn Tổ chức Code Tái hiện (Stage 3 — Khoảng 120 dòng Python) Code Architecture

3 Module cần viết bằng scikit-learn (Không cần cài đặt thư viện cũ bị lỗi)

Thư viện `scikit-multiflow` trong bài báo gốc (2018) đã ngừng phát triển và hay lỗi biên dịch C++ trên Python 3.11+. Nhóm bạn nên viết thẳng class `PageHinkley(delta=0.001, threshold=50)` bằng 15 dòng Python thuần (hoặc dùng thư viện kế nhiệm `river.drift.PageHinkley`) kết hợp trực tiếp với `scikit-learn`:

• **Module 1 (`detector.py`):** Class `PageHinkley` nhận đầu vào $e_t \in \{0, 1\}$, trả về `True` khi $m_t - M_t > \lambda$.

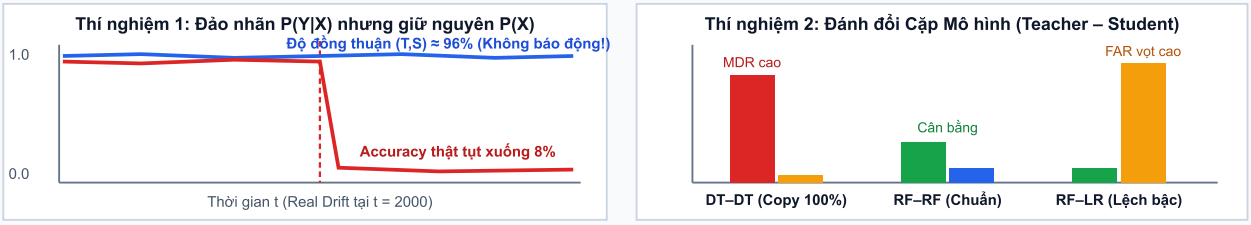
• **Module 2 (`studd.py`):** Hàm `select_best_model(X_w, y_w)` chọn cặp (T, S) theo

5. Vũ khí Phản biện Lý thuyết & Kịch bản Stress Testing

Stage 4 & Stage 5

Để đạt điểm tuyệt đối ở Stage 4 (*Theory Critique*) và Stage 5 (*Empirical Stress Testing*), nhóm cần đánh trúng **2 giả định ngầm chí mạng** mà chính tác giả đã hé lộ ngắn gọn ở Mục 5.6.1 (trang 4363), Hình 9 (trang 4367) và Mục 6.2 (trang 4374):

- **Điểm yếu 1 (Weakness 1 — Bị "mù hoàn toàn" trước Real Concept Drift thuần túy):** Theo công thức Bayes $p(X, y) = p(X) \cdot p(y \mid X)$, sai số bắt chước kỳ vọng trên luồng kiểm thử là $E_{X \sim p_t(X)}[I(T(X) \neq S(X))]$. Biểu thức này **chỉ phụ thuộc vào phân phối biên $p_t(X)$** và hoàn toàn độc lập với phân phối hậu nghiệm thật $p_t(y \mid X)$!
  → *Hệ quả toán học:* Nếu tại thời điểm t_{drift}, phân phối đầu vào $p(X)$ giữ nguyên ($p_t(X) = p_0(X)$) nhưng quy luật nhãn thật $p(y \mid X)$ bị đảo ngược hoàn toàn ($y_{new} = 1 - y_{old}$), các điểm dữ liệu x_i vẫn rơi vào vùng không gian quen thuộc lúc huấn luyện. Khi đó $T(x_i) = S(x_i)$ với xác suất gần như 100%, tức $L_i = 0$. Bộ báo động Page–Hinkley im lặng tuyệt đối trong khi độ chính xác thật của hệ thống sụp đổ về 0%!



Hình 3: Kết quả kỳ vọng cho 2 kịch bản Stress Testing ở Stage 5 (Trái: Real Drift Blindness; Phải: Teacher–Student Ablation).

Điểm yếu 2: Nghịch lý Cặp Mô hình Teacher – Student (Mục 5.6.1 & Hình 9)

Ablation Study

Ở Mục 5.6.1 (trang 4363), tác giả thừa nhận nếu Teacher quá đơn giản hoặc dễ đoán (ví dụ bộ phân loại lớp đa số hoặc mô hình yếu trên tập *Bike* ở Hình 9 trang 4367), Student sẽ đoán trúng hành vi của Teacher 100% ($\kappa_{Student} = 1.0$) ngay cả khi Teacher đoán sai toàn tập ($\kappa_{Teacher} = 0.0$). Nhóm sẽ thiết kế **Bảng Ablation 3 kịch bản cặp mô hình *(T, S)*** trên tập *AbruptInsects* và dữ liệu tổng hợp:

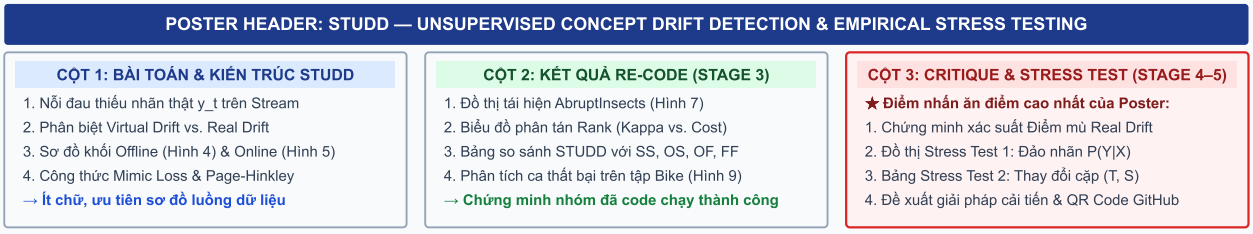
- **Kịch bản A — Over-mimicking (Trò copy Thầy tuyệt đối):** Đặt cả T và S là 1 cây `DecisionTreeClassifier(max_depth=5, random_state=42)`. Vì cùng thuật toán tất định trên cùng tập dữ liệu X_{tr}, hai cây chia nhánh giống hệt nhau trên toàn không gian $\mathbb{R}^q \rightarrow L_t \equiv 0$ mọi nơi → **Bỏ sót 100% mọi loại Drift (MDR = 1.0)**!
- **Kịch bản B — Capacity Mismatch (Lệch năng lực biểu diễn):** Đặt T là `RandomForestClassifier` (biên phi tuyến phức tạp) và S là `LogisticRegression` (siêu phẳng tuyến tính). Do đường thẳng không thể uốn theo biên cong, ngay cả khi chưa có Drift, S và T đã cãi nhau liên tục → **Báo động giả liên tục (FAR tăng vọt, tốn chi phí nhãn)**.

6. Kịch bản Thuyết trình Slide & Thiết kế Poster Nhóm

Stage 5: Presentation & Poster

Để bài báo cáo trên lớp và phiên chấm Poster gây ấn tượng mạnh nhất với giảng viên, nhóm nên chia bài thuyết trình thành **10 Slide cô đọng** đi từ trực giác đến thực nghiệm phản biện:

- **Slide 1–2 (Đặt vấn đề & Động lực):** Ví dụ trực quan về *Concept Drift* và bài toán duyệt vay tín dụng không có nhãn thật y_t tức thì (Đưa sơ đồ Hình 1 trang 4354 lên slide).
- **Slide 3–4 (Phương pháp STUDD):** Sơ đồ 2 giai đoạn *Teacher–Student* (Hình 4 & 5) + Công thức cộng dồn *Page–Hinkley* giải thích trong 3 dòng.
- **Slide 5–6 (Kết quả Tái hiện Stage 3):** Biểu đồ trượt *AbruptInsects* (Hình 7), *Posture* (Hình 8) và bảng so sánh *Cohen's Kappa vs. Labeling Cost* chứng minh STUDD tiết kiệm nhãn vượt trội.
- **Slide 7–8 (Phản biện Stage 4 & Thực nghiệm Mở rộng Stage 5):** Trình chiếu ca thất bại *Bike* (Hình 9 trang 4367) làm cầu nối sang **2 Vũ khí Stress Testing**: Đồ thị *Real Concept Drift* đảo nhãn và Bảng Ablation 3 cặp (T, S).
- **Slide 9–10 (Hướng cải tiến Hybrid & Kết luận):** Đề xuất kết hợp STUDD với một lượng nhỏ nhãn trễ (*Semi-supervised / Active Drift Detection* như gợi ý ở Mục 6.2 trang 4374).



Hình 4: Bố cục thiết kế Poster 3 cột chuẩn hội nghị khoa học (Tỷ lệ vàng: 30% Lý thuyết – 30% Tái hiện – 40% Phản biện & Mở rộng).

Bộ Câu hỏi Hội đồng Thường Hỏi (Q&A Phòng thủ Đồ án)

Tips Bảo vệ

2 câu hỏi xoáy sâu nhất từ Giảng viên & Cách trả lời ghi điểm

Câu hỏi 1: *"Nếu Teacher và Student cùng huấn luyện bằng Random Forest trên đúng 1 tập dữ liệu X_{tr}, tại sao chúng lại dự đoán khác nhau khi có Drift?"*

→ **Trả lời:** Thứ nhất, T học từ nhãn thật y_{tr}, còn S học từ nhãn dự đoán $\hat{y}_T$ (đã được làm mượt biên quyết định). Thứ hai, cơ chế Bagging (lấy mẫu Bootstrap) và chọn ngẫu nhiên tập con đặc trưng tại mỗi nút của Random Forest tạo ra các vùng biên quyết định khác nhau ở không gian ngoại lai (*Out-of-distribution*). Khi $p(X)$ dịch chuyển vào vùng ít mẫu, sự bất đồng giữa các cây trong T và S lập tức lộ diện.

Câu hỏi 2: *"Làm sao khắc phục việc STUDD bị mù trước Real Concept Drift?"*

→ **Trả lời:** Không một thuật toán thuần Unsupervised nào bắt được Real Drift nếu $p(X)$ đứng yên hoàn toàn. Giải pháp thực tế là kết hợp cơ chế **Active Verification**: bên cạnh báo động của STUDD, hệ thống định kỳ lấy mẫu ngẫu nhiên một tỷ lệ rất nhỏ (ví dụ 1%–5% nhãn trễ) để kiểm tra chéo sai số thật của Teacher.